

Rīgas 10.vidusskola

**Datu apjoma ietekmēšana uz mašīnmācīšanās rezultātiem  
«Snake» spēles piemērā**

Zinātniskās pētniecības darbs informātikas sekcijā

Darba autors:  
Jegors Baļzins

Darba vadītājs:  
informātikas skolotājs  
Vsevolods Antjufejevs

Rīga, 2018.

## **Anotācija**

Datu apjoma ietekmēšana uz mašīnmācīšanās rezultātiem «Snake» spēles piemērā, Jegors Balzins, darba vadītājs informātikas skolotājs Vsevolods Antjufejevs.

Darba mērķis: noteikt mašīnmācīšanu rezultātu atkarību no datu apjoma, apmācot programmu spēlet spēli «Snake».

Darba uzdevumi:

- izpētīt teoriju par temātu;
- izveidot vidi programmas apmācīšanai;
- izveidot apmācīšanas programmu;
- apmācīt programmu un notestēt to;
- savākt datus par apmācīšanas un testēšanās procesu;
- izveidot secinājumus.

Darba gaita: izpētīt teoretiska daļa, saņemt un apstrādāti dati par apmācīšanu

Darba rezultāts: mašīnmācīšanās rezultāts aug ar datu apjomu tikai līdz kādam momentam, un augot datiem pēc tā momentā rezultāts jau neaug vai samazinās.

## **Annotation**

Influence of amoun of data on machine learning results on example of «Snake» game, Jegors Balzins, supervisor teacher of Informatics Vsevolods Antjufejevs.

Goal of work: find dependence of machine learning results from amount of data, by teaching the programm to play game «Snake».

Tasks of work:

- explore the the theory on the theme;
- create environment for program to train;
- create training program;
- train program and test it;
- collect training and tasting data;
- make conclusions.

## Saturs

Datu apjoma ietekmēšana uz mašīnmācīšanās rezultātiem «Snake» spēles piemērā	1
Anotācija	2
Annotation	2
Saturs	3
Ievads	4
1. Teoretiska daļa	5
1.1. Spēle «Snake»	5
1.2. Mašīnmācīšanās	5
1.3. Pastiprinātas mācīšanās	5
1.4. «Q-learning»	5
1.5. «Python» programmēšanas valoda	5
2. Praktiska daļa	6
2.1. Vides sagatavošana	6
2.1.1. Palīgkods	6
2.1.2. «Čūskas» kods	6
2.1.3. Spēles kods	6
2.2. Aģenta gatavošana	6
2.3. Dati par vides stāvokli	6
2.4. Aģenta trenēšana	7
2.5. Aģenta testēšana	7
2.5. Dati par aģenta trenēšanu un testēšanu	7
2.6. Datu apstarāde	7
Secinājumi	8
Literatūras saraksts	9
Materiāli no internetā	9
Pielikumi	10

## Ievads

Mašīnmācīšanās ir populāra mākslīgas intelekta datorzinātņu nozāres apakšnozāre, kas mūsdien ļoti ātri attīstās. Visbiežāk mašīnmācīšanās izmanto tādu uzdevumu risināšanai, kuriem nav precīza vai pietiekami ātra atrisināšanās algoritma. Apmācīšanās procesā programma izmanto lielu datu apjomu, un ir interesānti uzzināt kā datu apjoms ietekmē apmācīšanās rezultātu. Lai to izpētīt labāk apskatīt vieglo piemēru, lai mazāk faktoru ietekmētu rezultātu. Laba ideja ir izpētīt šī jautājumu, apmācot programmu spēlet «Snake» spēli, jo dati ģenerējas spēles processā, un ir viegli saprast kuri parametri ir vissvarīgākie.

Darba mērķis: noteikt mašīnmācīšanu rezultātu atkarību no datu apjoma, apmācot programmu spēlet «Snake».

Darba uzdevumi:

- izpētīt teoriju par temātu;
- izveidot vidi programmas apmācīšanai;
- izveidot apmācīšanas programmu;
- apmācīt programmu un notestēt to;
- savākt datus par apmācīšanas un testēšanās procesu;
- izveidot secinājumus.

Hipoteze: lielākais datu apjoms novedīs pie labāka rezultāta.

# 1. Teoretiska daļa

## 1.1. Spēle «Snake»

Spēle «Snake» ir populāra datorspēle izdomāta 1977.gadā, kur spēletājs kontrolē maigo būtni, kura izskatās līdzīgi čūskai. Spēles noteikumi ir dažādi dažos versijas, bet koncepcē ir kāda izmēra laukā, kur pārvietojas būtne kaut kādā virzienā, kuru var mainīt spēletājs. Būtne sastāv no «galvas» un «astes». Kad galva satiek «barjeru», spēle beidzas, citādi turpinās. Ja būtne apēd «ābolu» aste pagarinās.

## 1.2. Mašīnmācīšanās

Mašīnmācīšanās ir mākslīgā intelekta apakšnozare, kurā nodarbojas ar tādu algoritmu izstrādi, kuri ļauj datoriem uzlabot lēmumu pieņemšanu, pamatojoties uz empīriskiem datiem. Izmantojot mašīnmācīšanās tehnikas, programma apmācas dot vairā vai mazāk līdzīgo labākajam atbildēm atbildi.

## 1.3. Pastiprinātas mācīšanās

Pastiprinātas mācīšanās ir mašīnmācīšanās veids, kuras apmacīšanas laikā aģents iedarbojas ar kādu vidi un saņem pastiprinājuma signālu jeb vides reakciju. Aģents ir programma, prognozē darbību dotajos vides apstākļos, un pēc saņemtajiem datiem par vides reakciju korektē savu prognozēšanas sistēmu.

## 1.4. «Q-learning»

«Q-learning» ir pastiprinātas mācīšanās tehnika, kad aģents veido noderības tabulu, kurā katrai vides stāvokļa un iespējamo darbību šī stāvokļa paras vērtībai tiek piešķirta noderība jeb cik noderīgi ir izpildīt šī darbību šajā stāvoklī. «Q-learning» algoritms ir ļoti viegls, tāpēc to ir viegli uzrakstīt ar jebkādu populāro programmēšanas valodu. Vispārināta veida «Q-learning» algoritms sastāv no šādiem soļiem:

1. Izveidot tabulu Q un piešķirt visiem  $Q_{s,a}$  (kur s ir vides stāvoklis, bet a ir tām derīga darbība) ar nejaušam vērtībam kādā diapozonā (tas ir atkarīgs no citiem parametriem)
2. Kaut kādu laiku atkārtot procesu(jo vairāk atkārtot, jo atkartos katrs stāvoklis):
3. Saņemt vides stāvokli - s un izvēlēties darbību ar lielāko noderību no visiem  $Q_s$  vērtībām un izdarīt to.
4. Saņemt balvu - r no vides
5. Atjaunot  $Q_{s,a}$  pēc formulas(kur  $\alpha$  ir mācīšanas temps un  $\gamma$  ir diskonta faktors):  
$$Q_{s,a} = (1 - \alpha) + \alpha(r + \gamma \cdot \max Q_{s+1}) \quad (1.)$$

## 1.5. «Python» programmēšanas valoda

«Python» ir populāra programmēšanas valoda, kuru plaši izmanto mašīnmācīšanās to vieglas sintakses un lielo bibliotēku ar atvērto kodu skaitu dēļ.

## **2. Praktiska daļa**

### **2.1. Vides sagatavošana**

Izmantojot teoretiskas zināšanas par spēli «Snake» un programmēšanas valodu «Python», varam uzrakstīt maksimālo vidi.

#### **2.1.1. Palīgkods**

Lai vidi un vēlāk aģentu būtu vieglāk testēt un rakstīt, vispirms uzrakstīsim palīg kodu, kur:

1. importēsim palīdzīgas bibliotēkas;
2. uzrakstīsim funkcijas, kurās veic matemātiskas aprēķināšanas, kā distances vai virziena pagriezumu aprēķināšana;
3. uzrakstīsim vides stavokļa izvadīšanas uz ekrāna funkcijas, lai pēc tām būtu vieglāk testēt

#### **2.1.2. «Čūska» kods**

Aprakstīsim «čūsku» kā klasi, kurā būs dati un metodi:

1. «čūska» kā koordinātu saraksts;
2. kustības virziens;
3. vai apēdis «ābolu» nākamā soli;
4. funkcija, kura pagriež virzienu pa labi;
5. funkcija, kura pagriež virzienu pa kreisi;
6. funkcija, kura teic «čūskai» izdarīt soli virzienā
7. palīg funkcijas

#### **2.1.3. Spēles kods**

Spēlei izveidosim funkcijas, lai no viena koda būtu iespēja dažreiz to spēlēt. Inicializēsim lauku kā 2D masīvu 20x20, kur sienas nav brīvas, un visas vertības un sāksim bezgalīgu ciklu. Katra iterācija aģents vai spēlētājs izveido darbību, un «čūska» to izdarīs, ja «čūska» satiks barjeru vai savu asti, tad spēle beigsies, ja «čūska» satiks «ābolu», tad «čūska» palielinās uz 1, un «ābols» parādīsies kāda neaizņemtā kvadrātā laukā, atjaunosim visas vertības un atkārtosim.

### **2.2. Aģenta gatavošana**

Uzrakstīsim aģentu kā klasu, kas satur noderības tabulu un izmanto, atjauno un saglāb tā datus. Aģents atjaunos datus tabulā pēc 1. formulas ( sk. 1.3. «Q-learning» ).

### **2.3. Dati par vides stāvokli**

Mēs zinām, ka aģents izmanto informāciju par vides stāvokli, bet kādu informāciju mums vajag dot? Vajag saprast, ka jo vairāk daždo stāvokļu var būt, jo labākus atbildes dos aģents, bet vairāk laiku vajadzēs apmācīšanai. Mūsu uzdevums nav dabū labāku rezultātu, bet noteikt kā noteikt rezultātu atkarību no datu apjoma. Tāpēc izmantosim tikai informāciju relatīvu (skatoties «čūskas» kustības virzienā) «ābola» pozīciju un kvadrātus priekšā, pa labi un pa kreisi no «čūskas» galvas - vai nomirs ja kustoties uz viņiem, kas dos apmēram 10000 dažādo vides stāvokļu.

## **2.4. Aģenta trenēšana**

Lai notrenēt aģentu definēsim cik iterāciju jāizdara trenēšanā laikā. Lai negaidīt daudz optimāls iterāciju skaits būs 100000, pēc tādu mēģinājumu skaitu tām jau jārada kaut kādu rezultātu. Arī definēsim mācīšanas tempu, diskonta faktoru un balvas par dažādiem sasniegumiem. Kamēr nebūs laba rezultāta. Kad to sasniegsim, trenēsim aģentu dažreiz ar dažiem iterāciju skaitiem. Jo vairā ir iterāciju, jo vairāk datu izmanto aģents, tāpēc varam uzskatīt, ka skatoties uz rezultāta no iterācijas jeb soļu skaitu, skatamies uz rezultāta no datu apjoma atkarību. Noderības tabulus saglabāsim failā.

## **2.5. Aģenta testēšana**

Lai notestēt aģentu atjaunosim tabulu no saglabāta faila un nospelēsim dažas spēles, skatoties, vai «čūskas» neit kāda ciklā, ja iet, tad sākt jauno. Rezultātus saglabāsim.

## **2.5. Dati par aģenta trenēšanu un testēšanu**

Izdarot šo procesu, es izveļos  $\alpha = 0.3$ ;  $\gamma = 0.3$ ; dot balvu -10 par pārvietošanos tālāk no «abola», -100 par spēles beigšanu, +100 par pārvietošanos tuvāk «ābolām», +500 par «ābola» āpēšanu. Staitistika par aģenta trenēšanu sk. tabula 1.

## **2.6. Datu apstarāde**

Vispirms, vajag teikt ka trenēšanas dati veidojas nejauši tāpēc trenēšanās procesā var radīties anomāles, kā 5. un 9. mēģinājumā (sk. 1. tabulu). Palielinot soļu skaitu līdz 1000000 rezultāts aug, neproporcionāli, bet aug, bet līdz 10000000 smazinās (sk. 1. tabulu). Tās var bū saistīts ar to, ka ir lielāka varbūtība tikt anamāli, bet ja to tikt, tā neļauj augt rezultātam pēc tā. Nav iespējas pārskatīt visus soļus, lai atrāst to, bet ir varam pieņemt, ka «čūska» sāk staigāt cikliski un nevar beigt.

## **Secinājumi**

Darba mērķis bija sasniegts, mašīnmācīšanu rezultāta atkarība no datu apjoma, apmācot programmu spēlet «Snake», bija atrāsta.

Darba uzdevumi ir izpildīti, teoretiska daļa bija izpētīta, vide izveidota, programmabija apmacīta, dati par apmācību bija saņemti un apstradāti, secinājums par datiem ir izveidots.

Dati parādīja, ka hipoteze bija nepareiza, un pēc tiem varam secināt, ka mašīnmācīšanās rezultāts aug ar datu apjomu tikai līdz kādam momentam, un augot datiem pēc tā momentā rezultāts jau neaug vai samazinās.

Ši darbs būs piejams visiem internetā (sk. 1. pielikumu) , lai izmantot to pētniecība vai apmacībā.



## **Literatūras saraksts**

- Себастьян Рашка «Python и машинное обучение.» ISBN 978-5-97060-409-0
- Саттон Ричард С., Барто Эндрю Г. «Обучение с подкреплением» ISBN 978-5-94774-351-7

## **Materiāli no internetā**

- <https://docs.python.org/3/>
- <http://cs229.stanford.edu/proj2016spr/report/060.pdf>
- <http://people.revoledu.com/kardi/tutorial/ReinforcementLearning/index.html>

# Pielikumi

tabula 1.

mēģinājums	vidēja punktu skaits apmācībā	lielākais punktu skaits apmācībā	vidējais soļu skaits dzīvē apmācībā	vidēja punktu skaits testēšanā	lielākais punktu skaits testēšanā	vidējais soļu skaits testēšanā
1 - 10000 soļi	3.75	10	85.48	4.3	11	422
2 - 10000 soļi	3.77	12	64.94	4.34	11	405.84
3 - 10000 soļi	3.89	19	65.8	4.76	11	302.37
4 - 100000 soļi	7.14	25	96.71	9.44	29	129.27
5 - 100000 soļi	4.10	11	645.17	4.78	15	488.53
6 - 100000 soļi	6.95	23	95.69	8.65	30	116.17
7 - 1000000 soļi	13.74	42	188.96	18.87	34	261.39
8 - 1000000 soļi	13.53	44	190.26	17.85	34	255.28
9 - 1000000 soļi	5.5	20	2092.05	6.34	18	250.21
10 - 10000000 soļi	5.68	22	18450.18	7.56	19	134.93
11 - 10000000 soļi	7.15	29	9337.07	8.93	37	241.16
12 - 10000000 soļi	6.82	23	10752.69	9.4	23	129.97

## 1. pielikums

Visi dati izveidoti pētījuma gaita ir pieejami:

<https://github.com/vebgor/QLearningSnake>